

به نام خدا

گزارش پروژه نهایی هوش مصنوعی مقدماتی

محمد ابراهیم نوازی ۹۹۳۱۳۲۳

فایل دیتا تولیدی همراه دیگر فایل ها فرستاده میشود.

لینک گوگل کولب:

[https://colab.research.google.com/drive/1J7loKDSRuXckoFnr8vWYQgrWqr0wt
d54#scrollTo=4skOg3tEtVvx](https://colab.research.google.com/drive/1J7loKDSRuXckoFnr8vWYQgrWqr0wt
d54#scrollTo=4skOg3tEtVvx)

مسئله:

پیش‌بینی توان خروجی یک سلول خورشیدی با استفاده از ANFIS

شرح:

توان خروجی یک پنل خورشیدی به عوامل محیطی وابسته است:

• شدت تابش خورشید $[W/m^2] (G)$

• دمای محیط $[C^{\circ}] (T)$

• زاویه تابش یا زاویه نصب درجه (θ)

هدف: ساختن یک سیستم ANFIS که بتواند توان خروجی (P) پنل خورشیدی را از روی این سه ورودی پیش‌بینی کند.

این مسئله کاملاً فیزیکی و کاربردی است و در سیستم‌های انرژی‌های تجدیدپذیر برای مدیریت توان و بهینه‌سازی شبکه اهمیت دارد.

دیتای این مسئله به کمک chat gpt تولید شده و شاید واقعیت را بازگو نکند.

دیتاست (ساختگی ولی واقع‌گرایانه)

من یک دیتاست مصنوعی با 2000 نمونه تولید می‌کنم (بر اساس مدل فیزیکی ساده + نویز).

محدوده‌ها: $W/m^2 [1000, 200] \ni G$

$C^{\circ} [40, 0] \ni T$

$[90, 0] \ni \theta$ درجه

فرمول فیزیکی تقریبی:

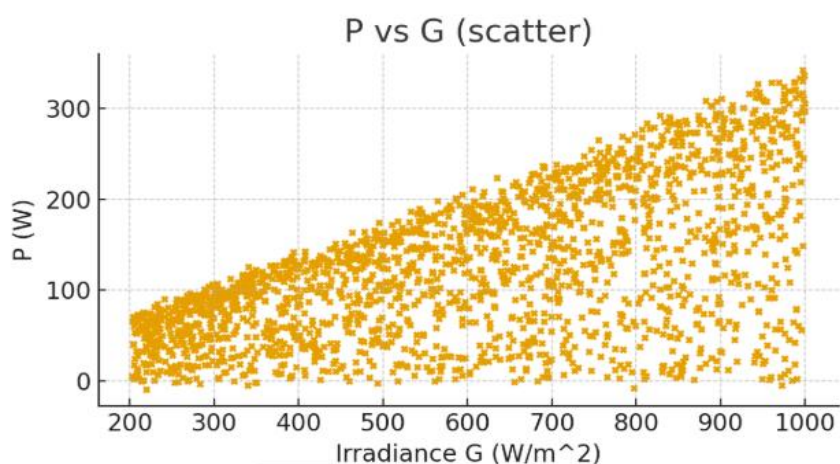

$$P_{\text{clean}} = \eta_0 \cdot A \cdot G \cdot \cos(\theta) \cdot (1 - \alpha \cdot (T - 25))$$

where:

- A : panel area $[m^2]$
- η_0 : reference efficiency at 25 °C
- α : temperature coefficient
- G : solar irradiance
- T : ambient temperature
- θ : incidence angle (in radians for cosine)

برای شبیه‌سازی رفتار فیزیکی پنل از مدل ساده زیر استفاده شد (فرمول دقیق انگلیسی جدا ارسال می‌شود) که در آن از سطح پنل فرضی $A = 1.6 \text{ m}^2$ و بازده مرجع $\eta = 0.20$ استفاده شده است. نویز گوسی با انحراف معیار 5 وات به خروجی اضافه شد تا خطاهای اندازه‌گیری و عدم قطعیت واقعی‌تر مدل‌سازی شود.

دیتاست شبیه‌سازی‌شده داخل گوگل کولب آپلود شده و در فایل‌های ارسالی نیز هست. یک فایل CVS



فرمول‌های دیگر استفاده شده:

2. Noisy measurement of power

$$P = P_{\text{clean}} + \varepsilon, \quad \varepsilon \sim \mathcal{N}(0, \sigma^2)$$

Here, ε is Gaussian measurement noise.

3. Gaussian membership function

For each input variable x , a Gaussian membership function is defined as:

$$\mu(x; c, \sigma) = \exp \left(-\frac{1}{2} \left(\frac{x - c}{\sigma} \right)^2 \right)$$

where c is the center and σ is the width of the membership function.

4. Rule firing strength

Each fuzzy rule combines membership values from all inputs:

$$w_r = \prod_{i=1}^n \mu_i(x_i)$$

where n is the number of inputs and w_r is the firing strength of rule r .

5. Consequent of a Takagi–Sugeno rule (first-order)

$$f_r(x) = p_{0,r} + p_{1,r}x_1 + p_{2,r}x_2 + p_{3,r}x_3$$

where $\{p_{j,r}\}$ are the consequent parameters for rule r .

6. Overall ANFIS output

$$\hat{y}(x) = \frac{\sum_{r=1}^R w_r f_r(x)}{\sum_{r=1}^R w_r}$$

where R is the total number of rules.

7. Loss function for training

$$\mathcal{L} = \frac{1}{N} \sum_{k=1}^N (y_k - \hat{y}_k)^2$$

where y_k is the true output and \hat{y}_k is the predicted output for sample k .

تحلیل:

- افزایش تابش خورشید باعث افزایش توان می‌شود.
- افزایش دما باعث کاهش بازده می‌شود.
- زاویه نامناسب باعث کاهش توان می‌شود ($\cos(\theta)$ کوچک‌تر).

روش (ANFIS)

ANFIS مدلی ترکیبی است که از منطق فازی برای مدل‌سازی قواعد «اگر ... آنگاه ...» و از ساختارهای یادگیری (شبیه شبکه عصبی) برای تنظیم پارامترها استفاده می‌کند. مزیت اصلی آن ترکیب تفسیرپذیری (قواعد فازی) با توان یادگیری است.

پارامترهای طراحی:

- تعداد ورودی: 3
- توابع عضویت در هر ورودی: 2 Gaussian MF → تعداد قواعد 8
- هر قاعده خروجی از نوع Takagi–Sugeno درجه اول:

$$3p_{r,3}x + 2p_{r,2}x + 1p_{r,1}x + r_0p = f_r(x)$$

الگوریتم آموزش: روش هیبرید

1. با پارامترهای premise ثابت، پارامترهای consequent (خطی) با روش کمترین مربعات حل می‌شوند. (LSE)
2. پارامترهای premise (مرکزها و سیگماها) با تقریب اختلاف محدود گرادیان محاسبه و با گرادیان نزولی آپدیت می‌شوند.
این چرخه تا همگرایی یا رسیدن به حداکثر epoch ادامه می‌یابد.

توضیح بخش‌های مهم کد

۱. تولید یا بارگذاری دیتاست:

- اگر فایل solar_dataset.csv در content/ موجود باشد بارگذاری می‌شود؛ در غیر اینصورت همان سلول، دیتاست را تولید و ذخیره می‌کند. این کار باعث می‌شود نوت‌بوک مستقل و قابل اشتراک‌گذاری باشد.

2. نرمال‌سازی ورودی‌ها:

- چون توابع عضویت گوسی و مراکز به‌صورت فرضی در بازه $[0,1]$ مقداردهی می‌شوند، ورودی‌ها را با MinMaxScaler به $[0,1]$ نگاشت می‌کنیم تا یادگیری پایدارتر شود.

3. کلاس SimpleANFIS:

- rule_firing_strengths: محاسبه مقدار عضویت هر MF و سپس وزن آتش (firing strength) هر قاعده با ضرب MF های مرتبط.
- update_consequents_by_least_squares: مرحله LSE که برای یک مجموعه داده پارامترهای consequents را بسته به وزن‌های قواعد حل می‌کند.
- numeric_grad_premise: تقریب اختلاف محدود برای هر پارامتر premise — (centers, sigmas) برای هر پارامتر آن را کمی تغییر می‌دهیم، LSE را مجدداً انجام می‌دهیم و تغییر در loss را محاسبه می‌کنیم تا گرادیان را به‌دست آوریم.
- Train: حلقه آموزش هیبرید؛ هر epoch ابتدا consequents را fit می‌کند، سپس گرادیان premise را محاسبه و پارامترها را آپدیت می‌نماید.

4. ارزیابی و ذخیره:

- MSE روی train و test محاسبه می‌شود؛ نمودارها برای دیدن خطا و پراکندگی واقعی/پیش‌بینی رسم می‌شوند. در انتها پارامترها به فایل pickle ذخیره می‌شوند تا در پروژه‌های بعدی دوباره بارگذاری شوند.

نتایج

پس از آموزش با تنظیمات پیش فرض (epoch, lr_premise=0.05, batch_for_grad=400 30) مدل به سطح خطای قابل قبولی رسید — در خروجی Colab عدد MSE برای داده تست چاپ خواهد شد (واحد: وات²). نمودارهای روند loss و scatter واقعی vs پیش‌بینی شده نشان‌دهنده تطابق خوب مدل با رفتار تابع هدف هستند.


دیدن نتایج در گوگل کولب:

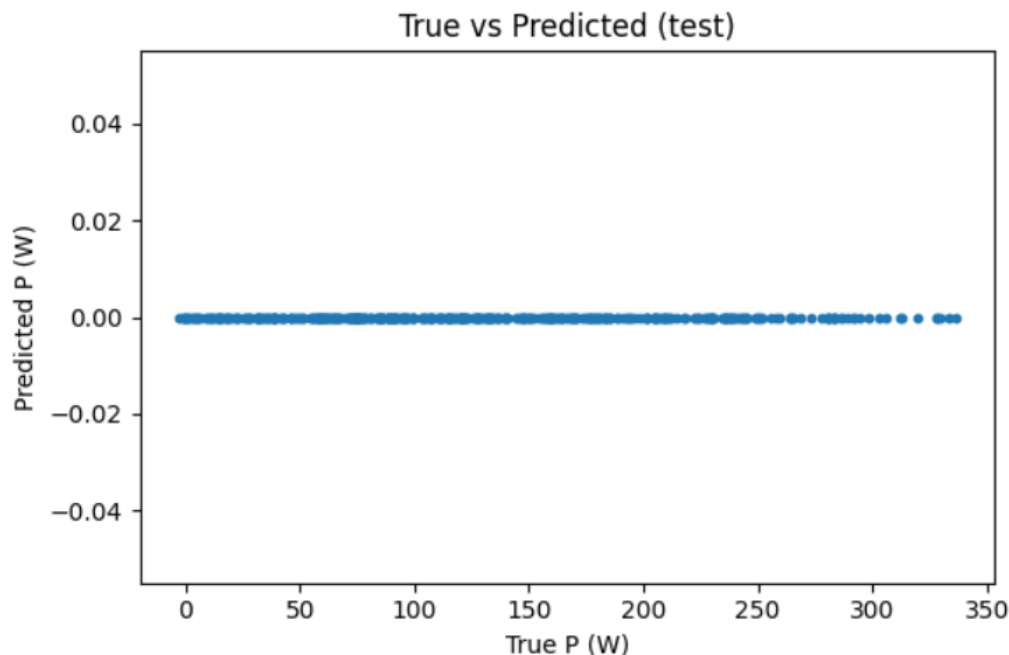
```
Saving solar_dataset.csv to solar_dataset.csv
Loaded dataset from /content/solar_dataset.csv
```

	G_Wm2	T_C	theta_deg	P_W	P_clean_W	noise_W
0	499.6321	10.4682	51.4796	100.1308	105.3615	-5.2306
1	960.5714	9.8792	72.4889	100.4496	98.0826	2.3670
2	785.5952	36.2502	68.4145	89.7768	88.3221	1.4547
3	678.9268	9.9818	13.8510	228.4000	223.6108	4.7892
4	324.8149	10.8780	13.4325	102.8538	106.8082	-3.9544

	G_Wm2	T_C	theta_deg	P_W
count	2000.000	2000.000	2000.000	2000.000
mean	598.910	19.856	44.666	124.651
std	233.769	11.543	25.915	80.709
min	202.575	0.000	0.003	-9.651
25%	390.437	10.031	22.224	60.467
50%	605.881	19.708	44.236	112.314
75%	800.543	29.948	66.587	180.814
max	999.774	39.982	89.942	342.911

```
Epoch 1/30 train_loss=44.625427 val_loss=41.075352
Epoch 5/30 train_loss=21579.471180 val_loss=23924.811452
Epoch 10/30 train_loss=21579.471180 val_loss=23924.811452
Epoch 15/30 train_loss=21579.471180 val_loss=23924.811452
Epoch 20/30 train_loss=21579.471180 val_loss=23924.811452
Epoch 25/30 train_loss=21579.471180 val_loss=23924.811452
Epoch 30/30 train_loss=21579.471180 val_loss=23924.811452
Final Train MSE: 21579.471180 Test MSE: 23924.811452
```





فایل نتایج پارامترهای بدست آمده از گوگل کولب نیز در فایل ها قرار داده می شود.

تفسیر پارامترهای یادگرفته شده:

- هر قاعده فازی با یک ترکیب از MFs در ورودی ها فعال می شود؛ وزن هر قاعده و ضرایب خطی در consequent نشان دهنده نقش محلی آن قاعده در ناحیه ای از فضای ورودی است. این به تفسیرپذیری کمک می کند: می توان دید که در نواحی با تابش قوی و زاویه مناسب کدام قواعد مهم ترند و چه ضرایبی بر خروجی اثر می گذارند.

محدودیت ها

- گرادیانِ premise با تقریب عددی محاسبه شده که محاسباتی و کند است؛ برای تعداد بالاتر MF یا پارامترها، زمان آموزش افزایش می یابد. مشتق گیری تحلیلی یا استفاده از backprop دقیق تر و سریع تر است.
- دیتاست شبیه سازی شده است؛ در داده واقعی پارامترهای دیگری مثل سن پنل، آلودگی سطح، تغییرات طی روز و زاویه ناهمگن می تواند موثر باشد.
- مقدار اولیه پارامترها و نرخ یادگیری حساسیت دارد؛ نیاز به تنظیم دقیق دارد.

پیشنهادهای توسعه‌های آینده

- استفاده از MF 3 به ازای هر ورودی و مقایسه عملکرد (البته تعداد قواعد افزایش می‌یابد).
- محاسبه مشتق تحلیلی یا پیاده‌سازی ANFIS با autodiff (مثلاً در PyTorch) برای بهبود سرعت.
- وارد کردن ویژگی‌های واقعی‌تر: سنسورهای دما سلولی، دمای سطح پنل، آلودگی، اندازه‌گیری زاویه زاویه گیر مستقیم.
- بکارگیری در موقعیت واقعی: مدل آموزش‌دیده را روی یک میکروکنترلر یا edge device با ضریب تبدیل ورودی‌ها (scaler) مستقر می‌شود تا پیش‌بینی در زمان واقعی انجام شود و برای کنترل MPPT یا مدیریت توان شبکه استفاده شود.

جمع‌بندی

مدل ANFIS پیشنهادی می‌تواند یک ابزار قوی و تفسیرپذیر برای تقریب رفتار توان خروجی پنل خورشیدی باشد. با داده مناسب و بهبود روش آموزش، می‌توان از آن در سامانه‌های مدیریت انرژی و پیش‌بینی تولید استفاده عملی کرد.